

บทที่ 1

บทนำ (Introduction)

1.1 ความเป็นมาและความสำคัญของปัญหา

ในยุคปัจจุบัน

สุขภาพจิตของนักเรียนและนักศึกษาในระดับอุดมศึกษาได้กลายเป็นหนึ่งในประเด็นทางสาธารณสุขและระบบการศึกษาที่สำคัญอย่างยิ่ง การเปลี่ยนแปลงอย่างรวดเร็วของสังคม แรงกดดันด้านผลการเรียน ปัญหาการปรับตัว และความเครียดสะสม ส่งผลให้อัตราการเกิดภาวะซึมเศร้า (Depression), โรควิตกกังวล (Anxiety) และภาวะตื่นตระหนก (Panic Attack) มีแนวโน้มเพิ่มสูงขึ้นอย่างต่อเนื่อง

สถาบันการศึกษาหลายแห่งจึงเริ่มนำเทคโนโลยีการเรียนรู้ของเครื่อง (Machine Learning: ML) และปัญญาประดิษฐ์ (Artificial Intelligence: AI) เข้ามาประยุกต์ใช้เพื่อคัดกรอง จำแนก และประเมินความเสี่ยงด้านสุขภาพจิตของผู้เรียนล่วงหน้า

เพื่อให้ฝ่ายแนะแนวและผู้เชี่ยวชาญสามารถยื่นมือเข้าให้ความช่วยเหลือได้อย่างทันท่วงที

อย่างไรก็ตาม ข้อมูลสุขภาพจิต (Mental Health Data) จัดเป็น ข้อมูลส่วนบุคคลที่มีความอ่อนไหวเป็นพิเศษ (Sensitive Personal Data) ภายใต้พระราชบัญญัติคุ้มครองข้อมูลส่วนบุคคล พ.ศ. 2562 (Personal Data Protection Act: PDPA) รวมถึงมาตรฐานสากล เช่น General Data Protection Regulation (GDPR) และ Health Insurance Portability and Accountability Act (HIPAA) การส่งข้อมูลสุขภาพจิตดิบ (Raw Sensitive Data) เช่น ข้อมูลอายุ ผลการเรียน ประวัติการรักษา หรือคำตอบแบบประเมินภาวะทางอารมณ์ ไปยังระบบประมวลผลบนคลาวด์เซิร์ฟเวอร์แบบดั้งเดิม (Centralized Cloud-based ML Inference) ก่อให้เกิดความเสี่ยงอย่างร้ายแรง 3 ประการ ได้แก่:

1. ความเสี่ยงต่อการละเมิดความเป็นส่วนตัวและการรั่วไหลของข้อมูล (Data Breach & Eavesdropping): ข้อมูลดิบอาจถูกดักจับระหว่างการส่งผ่านเครือข่าย หรือถูกเข้าถึงโดยผู้ดูแลระบบและบุคคลภายนอกที่ไม่ได้รับอนุญาต
2. ความไม่ไว้วางใจในการเปิดเผยข้อมูลของผู้เรียน (Stigmatization & Self-Censorship): นักเรียนส่วนใหญ่อาจไม่กล้าตอบแบบประเมินตามความเป็นจริง หรือเลือกที่จะปฏิเสธการประเมิน เพราะกังวลว่าข้อมูลจะถูกเปิดเผยและส่งผลกระทบต่อสถานะทางวิชาการและสังคม
3. ข้อจำกัดในการปฏิบัติตามกฎหมายคุ้มครองข้อมูลส่วนบุคคล (Legal & Compliance Constraints): สถาบันการศึกษาต้องแบกรับภาระทางกฎหมายในการจัดเก็บและประมวลผลข้อมูลสุขภาพจิต ทำให้หลายองค์กรหลีกเลี่ยงการนำโมเดล AI มาใช้งาน

เพื่อก้าวข้ามข้อจำกัดดังกล่าว แนวคิด การอนุมานโมเดลการเรียนรู้ของเครื่องแบบรักษาความเป็นส่วนตัว (Privacy-Preserving Machine Learning: PPML) จึงได้รับการพัฒนาขึ้น

โดยหนึ่งในเทคโนโลยีทางรหัสวิทยาที่มีศักยภาพสูงสุดในปัจจุบันคือ พยานหลักฐานความรู้เป็นศูนย์ (Zero-Knowledge Proofs: ZKP) ซึ่งเป็นโปรโตคอลที่ช่วยให้ผู้พิสูจน์ (Prover เช่น ตัวนักเรียนหรืออุปกรณ์ฝั่ง Client) สามารถพิสูจน์ความถูกต้องของข้อความหรือผลการประมวลผลต่อผู้ตรวจสอบ (Verifier เช่น Server ของสถาบันการศึกษา) ได้อย่างสมบูรณ์ทางคณิตศาสตร์ โดยไม่ต้องเปิดเผยข้อมูลนำเข้าที่เป็นความลับ (Private Inputs) ออกไปแม้แต่บิตเดียว

อย่างไรก็ดี การผสมผสาน Zero-Knowledge Proofs เข้ากับโมเดลการเรียนรู้ของเครื่อง (ZK-ML)

ยังเผชิญความท้าทายสำคัญทางเทคนิค คือ วงจรเลขคณิต ZK (ZK Arithmetic Circuits)

สามารถประมวลผลได้เฉพาะตัวเลขจำนวนเต็มบนฟิลด์จำกัด (Finite Field Arithmetic) เท่านั้น

ในขณะที่โมเดลการเรียนรู้ของเครื่องทั่วไปจะคำนวณด้วยตัวเลขทศนิยมความละเอียดสูง (Floating-point Arithmetic: Float64/Float32) ดังนั้น การแปลงโมเดลด้วย การควอนไทเซชันแบบจุดคงที่ (Integer Fixed-Point Quantization) จึงเป็นขั้นตอนสำคัญอย่างยิ่ง หากเลือกค่าตัวคูณสเกล (Scaling Factor: \$\$\$) ต่ำเกินไป จะทำให้เกิดการสูญเสียข้อมูลสำคัญ (Information Annihilation) และโมเดลสูญเสียความแม่นยำ แต่หากเลือกค่าสูงเกินไป จะเกิดความเสี่ยงต่อปัญหาตัวเลขล้น (Integer Overflow) บนฟิลด์จำกัด

วิทยานิพนธ์ฉบับนี้จึงมุ่งเน้นการวิจัย พัฒนา และประเมินผลระบบ Privacy-Preserving Machine Learning Inference โดยใช้ Zero-Knowledge Proofs บนข้อมูลสุขภาพจิตนักเรียน โดยเลือกใช้ภาษา Noir DSL (Nargo) ในการสร้างวงจร ZK Circuit และพัฒนาระบบคอนโทรลเลอร์ที่เหมาะสมที่สุด ($S=1,000$) เพื่อให้ได้ระบบคัดกรองสุขภาพจิตที่มีความแม่นยำ 100% ไม่สูญเสียความถูกต้องเมื่อเทียบกับ Floating-point Baseline มีความเร็วในการสร้าง Proof ในระดับต่ำกว่าวินาที (~ 185.4 ms) และสอดคล้องกับมาตรฐานความปลอดภัย PDPA อย่างสมบูรณ์

1.2 คำถามงานวิจัย (Research Questions)

- สามารถออกแบบและสร้างวงจรพยานหลักฐานความรู้เป็นศูนย์ (ZK Circuit) เพื่อทำการอนุมานโมเดลจำแนกความเสี่ยงสุขภาพจิตนักเรียนได้อย่างไร โดยไม่เปิดเผยข้อมูลสุขภาพจิตดิบและคงความถูกต้องของการอนุมานไว้ได้อย่างสมบูรณ์?
- การทำ Integer Fixed-Point Quantization ที่ระดับตัวคูณสเกล (S) ต่าง ๆ ส่งผลกระทบต่อความแม่นยำ (Accuracy), ความคลาดเคลื่อนของคะแนน (Score Drift MAE) และความถูกต้องของโมเดลเมื่อคำนวณบน ZK Finite Field อย่างไร?
- ค่าตัวคูณสเกล (S) และสถาปัตยกรรมโมเดลใดที่เป็นจุดสมดุลที่ดีที่สุด (Optimal Trade-off) ระหว่างความถูกต้องของการทำนาย ขนาดของวงจร (Circuit Constraints) และเวลาในการสร้างพยานหลักฐาน (Proving Latency)?
- ประสิทธิภาพทางรหัสวิทยา (Cryptographic Performance) และความพร้อมในการนำระบบ ZK-ML ไปประยุกต์ใช้งานจริงผ่านเว็บแอปพลิเคชันและ RESTful API มีความเหมาะสมเพียงใด?

1.3 วัตถุประสงค์ของการวิจัย (Research Objectives)

- เพื่อออกแบบและพัฒนาระบบการอนุมานโมเดลการเรียนรู้ของเครื่องแบบรักษาความเป็นส่วนตัว (PPML Inference System) โดยใช้เทคโนโลยี Zero-Knowledge Proofs (ZKP) ผ่านภาษา Noir

DSL เพื่อให้สามารถคัดกรองความเสี่ยงสุขภาพจิตของนักเรียนได้โดยไม่ต้องเปิดเผยข้อมูลดิบแก่ Server หรือบุคคลภายนอก

2. เพื่อพัฒนากระบวนการควอนไทเซชันแบบจำนวนเต็มจุดคงที่ (Integer Fixed-Point Quantization) สำหรับแปลงค่าน้ำหนัก (Weights) และค่าเอนเอียง (Bias) ของโมเดลจำแนกประเภท (Logistic Regression) ให้อยู่ในรูปตัวเลขจำนวนเต็ม i32 ที่สามารถคำนวณบน ZK Finite Field Arithmetic ได้อย่างมีประสิทธิภาพและปลอดภัยจากปัญหา Integer Overflow
3. เพื่อศึกษาและทดลองเชิงประจักษ์ (Empirical Benchmark) ถึงผลกระทบของค่า Scaling Factor ($S \in \{1, 5, 10, 50, 100, 500, 1000, 5000, 10000, 100000\}$) ที่มีต่อความแม่นยำ (Accuracy, F1-Score), ความคลาดเคลื่อนของคะแนน (Score Drift MAE) และการจับคู่ผิดพลาด (Classification Mismatches)
4. เพื่อประเมินประสิทธิภาพทางรหัสวิทยาและสถาปัตยกรรมระบบ (Cryptographic & System Evaluation) ในด้านจำนวน Opcodes/Constraints ของวงจร, เวลาในการสร้างหลักฐาน (Proving Latency), เวลาในการตรวจสอบ (Verification Latency) และการผสานรวมเข้ากับระบบเว็บแอปพลิเคชันแบบ MVC ด้วย FastAPI และ MySQL

1.4 สมมติฐานการวิจัย (Research Hypotheses)

1. การใช้เทคโนโลยี Zero-Knowledge Proofs ร่วมกับภาษา Noir DSL สามารถทำการอนุมานโมเดลสุขภาพจิตนักเรียนได้โดยที่ Verifier ไม่สามารถล่วงรู้ค่าของ Private Features (age, cgpa, depression, anxiety, panic_attack, seek_treatment) ได้
2. การทำ Integer Fixed-Point Quantization ที่ค่า Scaling Factor ที่เหมาะสม ($S \geq 10$ จนถึง $S = 1,000$) จะสามารถรักษาความแม่นยำของโมเดลไว้ได้เท่ากับโมเดล Floating-point ดั้งเดิม (Accuracy 100.0%, $\Delta \text{Accuracy} = 0.0\%$) โดยไม่มีข้อผิดพลาดในการจำแนกประเภท (Mismatches = 0)

3. วงจร ZK Circuit ที่สร้างจากโมเดล Logistic Regression จะมีขนาดกะทัดรัด (Ultra-Lightweight ≤ 500 Constraints) และมี Proving Latency ในระดับต่ำกว่าวินาที (Sub-second ≤ 300 ms) ซึ่งมีประสิทธิภาพสูงกว่าโมเดลที่มีโครงสร้างแบบ Branching (เช่น Decision Tree / Random Forest)

1.5 ขอบเขตของการวิจัย (Scope of the Study)

1.5.1 ขอบเขตด้านชุดข้อมูลและการจำแนกความเสี่ยง (Data Scope)

- ใช้ชุดข้อมูลสุขภาพจิตของนักเรียน (student_mental_health.csv / mental_health_records) ประกอบด้วยคุณลักษณะ (Features) จำนวน 6 ตัวแปร ได้แก่:
 - อายุ (Age): ตัวเลขจำนวนเต็ม
 - ผลการเรียนเฉลี่ยสะสม (CGPA): ตัวเลขทศนิยมที่แปลงสเกลเป็นจำนวนเต็ม (cgpa_scaled)
 - ภาวะซึมเศร้า (Depression): ข้อมูลทวิภาค (Binary: 0 = ไม่มี, 1 = มี)
 - ภาวะวิตกกังวล (Anxiety): ข้อมูลทวิภาค (Binary: 0 = ไม่มี, 1 = มี)
 - ภาวะตื่นตระหนก (Panic Attack): ข้อมูลทวิภาค (Binary: 0 = ไม่มี, 1 = มี)
 - การเคยเข้ารับการปรึกษา/รักษา (Seek Treatment): ข้อมูลทวิภาค (Binary: 0 = ไม่เคย, 1 = เคย)
- จำแนกผลลัพธ์เป็น 2 กลุ่ม (Binary Classification):
 - คลาส 0 (Low Risk / Normal): ความเสี่ยงต่ำ ไม่จำเป็นต้องได้รับการดูแลเร่งด่วน
 - คลาส 1 (High Risk / Support Recommended): ความเสี่ยงสูง แนะนำให้พบผู้เชี่ยวชาญ
- ร่องรับมาตรฐานรหัสย่อระดับการศึกษา (Standardized Education Level Enums): PP, PE, LSE, USE_VS, BBDL, BD, MD, PHD และกำหนดค่าเริ่มต้นเป็น UNK (Unknown/Not Specified)

1.5.2 ขอบเขตด้านโมเดลการเรียนรู้ของเครื่อง (Machine Learning Scope)

- เลือกใช้โมเดล Logistic Regression Classifier ซึ่งคำนวณผ่านผลรวมเชิงเส้น (Linear Combination):
$$\text{Score} = \sum_{i=0}^5 (w_i \cdot x_i) + b$$

- ฝึกสอนโมเดลด้วย Scikit-Learn และแปลงพารามิเตอร์ w_i และ b ด้วย Integer Fixed-Point Quantization Engine

1.5.3 ขอบเขตด้านเทคโนโลยีรหัสวิทยาและวงจร ZK (Cryptographic & ZKP Scope)

- พัฒนางจร ZK Circuit ด้วยภาษา Noir DSL (Version เข้ากันได้กับ Nargo CLI)
- แบ่งแยกตัวแปรในวงจร (circuit/src/main.nr) อย่างเคร่งครัด:
 - **Private Inputs:** ตัวแปรข้อมูลสุขภาพจิตของนักเรียนทั้ง 6 รายการ
 - **Public Inputs:** พารามิเตอร์สากลของโมเดล (weights, bias, threshold, expected_risk_class)
- กำหนดเงื่อนไขตรวจสอบในวงจรผ่านคำสั่ง `\text{assert}(\text{computed\_risk} == \text{expected\_risk\_class})` บน Finite Field Type i32

1.5.4 ขอบเขตด้านการพัฒนาระบบและสถาปัตยกรรม (System & Software Scope)

- พัฒนาระบบ Back-end API ตามสถาปัตยกรรม MVC (Model-View-Controller) ด้วย Python 3.11, FastAPI และ Uvicorn
- จัดการฐานข้อมูลเชิงสัมพันธ์ด้วย MySQL 8.0 และ SQLAlchemy ORM พร้อมระบบ Hybrid Data Provider (อ่านจาก DB ก่อน และ Fallback ไปยัง CSV อัตโนมัติ)
- ออกแบบหน้าแสดงผลการทดลองเชิงโต้ตอบ (Interactive Benchmark Dashboard) ด้วย Jinja2 Templates และ Chart.js
- รองรับการ Deploy ระบบด้วย Docker Compose, Caddy Reverse Proxy (HTTPS Auto-SSL) และ CI/CD Pipeline ผ่าน GitHub Actions

1.5.5 ขอบเขตด้านการวัดผลและเกณฑ์การประเมิน (Evaluation Metrics Scope)

- ด้าน Machine Learning: วัดค่า Accuracy, Precision, Recall, F1-Score, $\Delta \text{Accuracy}$, และ Score Drift Mean Absolute Error (MAE)
- ด้าน Cryptography: วัดจำนวน ACIR Opcodes, Brillig Opcodes, Mean Proving Latency, P95 Latency, และ Verification Latency

1.6 ข้อตกลงเบื้องต้นและข้อจำกัดของการวิจัย (Assumptions and Limitations)

1. ข้อตกลงเบื้องต้น (Assumptions):

- อุปกรณ์ฝั่ง Client (เช่น คอมพิวเตอร์หรือสมาร์ทโฟนของนักเรียน) มีขีดความสามารถในการประมวลผลคำสั่ง Nargo / ZK Prover สำหรับสร้าง Witness และ Proof
- ชุดข้อมูลสุขภาพจิตที่นำมาฝึกสอนและทดสอบมีความถูกต้องและผ่านการทำความสะอาดข้อมูล (Data Preprocessing) แล้ว

2. ข้อจำกัดของการวิจัย (Limitations):

- การวิจัยนี้มุ่งเน้นโมเดลจำแนกประเภทเชิงเส้น (Linear Separable) หากนำไปใช้กับชุดข้อมูลที่มีความสัมพันธ์แบบไม่เป็นเชิงเส้นสูง (Highly Non-linear) อาจต้องอาศัยการประมาณค่าพหุนาม (Polynomial Approximation) หรือเครือข่ายประสาทเทียม (Neural Networks) ซึ่งจะเพิ่มขนาด Circuit Constraints
- การประมวลผลบน ZK Finite Field ต้องระวังการเกิด Overflow สำหรับค่า Scaling Factor ที่มีขนาดใหญ่มาก ($\$S \geq 100,000\$$)

1.7 คำจำกัดความศัพท์เฉพาะ (Definition of Operational Terms)

- Zero-Knowledge Proofs (ZKP / พยานหลักฐานความรู้เป็นศูนย์):**
โปรโตคอลทางวิทยาการรหัสลับที่เปิดโอกาสให้ฝ่ายหนึ่ง (Prover) สามารถพิสูจน์ให้อีกฝ่ายหนึ่ง (Verifier) ทราบว่าข้อความหนึ่งเป็นจริง โดยไม่จำเป็นต้องเปิดเผยข้อมูลอื่นใดนอกเหนือไปจากความจริงของข้อความนั้น
- ZK-ML (Zero-Knowledge Machine Learning):** การประยุกต์ใช้ ZKP
ในกระบวนการเรียนรู้ของเครื่อง เพื่อให้สามารถตรวจสอบความถูกต้องของการอนุมานโมเดล (Inference Verification) โดยไม่เปิดเผยข้อมูลนำเข้า (Private Data) หรือสถาปัตยกรรมโมเดลที่ต้องการปกปิด
- Noir DSL:** ภาษาโปรแกรมเฉพาะโดเมน (Domain-Specific Language: DSL) ที่พัฒนาโดย Aztec Network สำหรับเขียนวงจรเลขคณิต ZK Arithmetic Circuits และคอมไพล์ออกมาเป็น Abstract Circuit Intermediate Representation (ACIR)
- Integer Fixed-Point Quantization:** กระบวนการแปลงค่าตัวเลขทศนิยม (Floating-point) ให้กลายเป็นตัวเลขจำนวนเต็ม (Integer) โดยการคูณด้วยตัวคูณสเกลคงที่ (S) แล้วปัดเศษ ($Q(x) = \text{round}(x \times S)$) เพื่อให้สามารถคำนวณบน ZK Finite Field ได้
- Score Drift (Mean Absolute Error: MAE):**
ค่าความคลาดเคลื่อนเฉลี่ยสัมบูรณ์ระหว่างคะแนนทำนายจากโมเดล Float64 ดั้งเดิม กับคะแนนที่ได้จากโมเดลที่ผ่านการ Quantize
- Constraint / ACIR Opcode:** หน่วยวัดความซับซ้อนของวงจร ZK โดย 1 Constraint หรือ Opcode คือสมการข้อจำกัดทางคณิตศาสตร์ใน Finite Field
ซึ่งส่งผลโดยตรงต่อเวลาและทรัพยากรที่ใช้ในการสร้าง Proof

1.8 ประโยชน์ที่คาดว่าจะได้รับ (Expected Benefits and Contributions)

- ด้านวิชาการและวิทยาการข้อมูล (Academic & Data Science Contributions):**

- a. ได้แบบจำลองและแนวทางการแปลงโมเดล Machine Learning เข้าสู่วงจร ZK Finite Field โดยใช้วิธี Integer Fixed-Point Quantization ที่พิสูจน์แล้วว่าไม่สูญเสียความแม่นยำ ($\Delta \text{Accuracy} = 0.0\%$ ที่ $S=1,000$)
- b. ได้ชุดข้อมูลเปรียบเทียบเชิงประจักษ์ (Empirical Benchmark) ระหว่างโมเดลเชิงเส้นและโครงสร้างอื่น ๆ ในมิติของความถูกต้องและ Cryptographic Constraints

2. ด้านการคุ้มครองข้อมูลส่วนบุคคลและสิทธิมนุษยชน (Privacy & Legal Compliance):

- a. ยกระดับการคัดกรองสุขภาพจิตนักเรียนให้สอดคล้องกับ พ.ร.บ. คุ้มครองข้อมูลส่วนบุคคล (PDPA), GDPR และ HIPAA อย่างเคร่งครัด ป้องกันปัญหาข้อมูลรั่วไหล 100%
- b. สร้างความมั่นใจให้นักเรียนในการประเมินตนเองโดยไม่ต้องกังวลเรื่องการถูกตีตรา (De-stigmatization)

3. ด้านการประยุกต์ใช้เชิงวิศวกรรมซอฟต์แวร์ (Engineering & Practical Implementation):

- a. ได้ระบบเว็บแอปพลิเคชันและ Asynchronous RESTful API ต้นแบบที่มีประสิทธิภาพสูง สามารถตอบสนองผลการพิสูจน์ได้ภายในเวลา ~ 185.4 มิลลิวินาที (Sub-second response)
- b. สถาบันการศึกษาสามารถนำ Source Code และสถาปัตยกรรมระบบไปติดตั้งใช้งานจริง (Production Deployment) ผ่าน Docker และ CI/CD Pipeline ได้ทันที